INTRODUCCIÓN PRÁCTICA A LA GENÓMICA DE POBLACIONES

IV. MÉTODOS PARA LA ESTIMACIÓN DE FUERZAS DE SELECCIÓN

Maria José Ruiz, Enrico Bazzicalupo, Lorena Lorenzo

Gabinete de Formación CSIC

23-27 Marzo 2026

Estación Biológica Doñana CSIC

Clasificación

Según sus efectos sobre el fenotipo:

- **Estabilizadora**: se favorecen los fenotipos intermedios.
- **Direccional:** se favorece un fenotipo extremo. Cambio evolutivo
- **Disruptiva:** se favorecen los fenotipos extremos. Divergencia y especiación

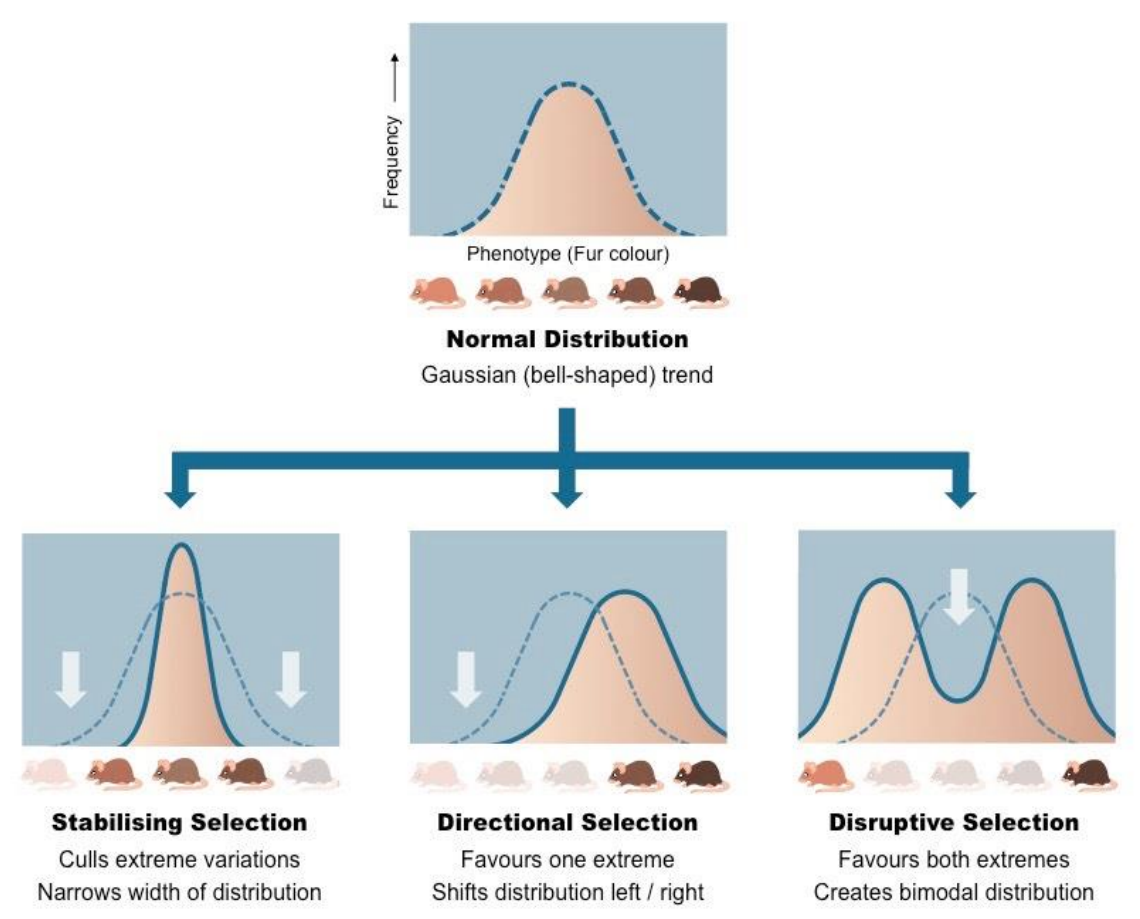

Clasificación

Según sus efectos sobre las frecuencias alélicas:

- **Positiva:** el alelo confiere una ventaja adaptativa con lo que aumentará en frecuencia en la población.
- **Negativa, purificadora, de fondo**: el alelo confiere una desventaja adaptativa, con lo que decrecerá en frecuencia en la población
- **Balanceadora:** múltiples alelos se mantienen en la población a frecuencias superiores a las esperadas solo por deriva.

Selección balanceadora

- Mantiene diferentes alelos a frecuencias intermedias en la población
- Alta diversidad nucleotídica (π)
- Puede ocurrir por diferentes mecanismos: ventaja del heterocigoto, selección dependiente de frecuencia y selección temporal y/o espacial

I. DETECCIÓN

Exceso de heterocigosidad y déficit de sustituciones

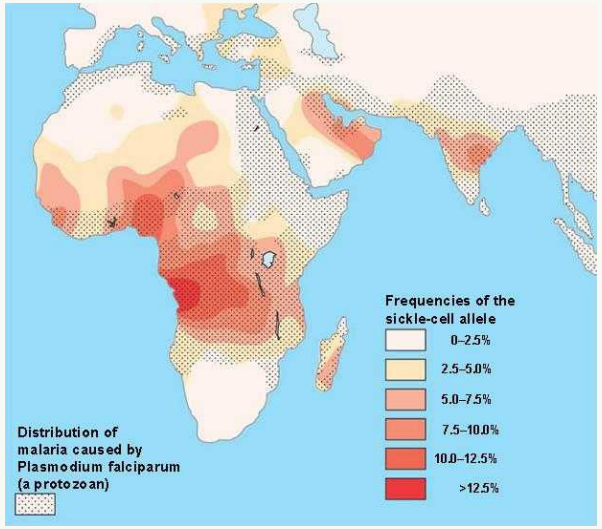

Distorsiones en el espectro de frecuencias

Selección negativa o purificadora

- El alelo desfavorecido disminuye en frecuencia en la población
- Disminución de la diversidad genética
- Los alelos recesivos deletéreos se eliminarán MUY lentamente cuando sean raros (< 0,10) porque habrá muy pocos homocigotos (si q = 0,1, entonces q^2 = 0,01).
- Estos alelos son la principal fuente de **depresión endogámica** (disminución eficacia biológica)

I. DETECCIÓN

Anotación funcional de variantes

Predicción del efecto y el impacto de las variaciones genéticas *(SnpEff)*

EFECTO

- Sinónimas
- No sinónimas
- Indels
- Interrupción splice site
- Stop Codon ganancia/pérdida
- Regiones reguladoras
- Intrones
- Intergénico

IMPACTO

- Moderado
- Bajo
- Sin impacto

Selección positiva

- El alelo favorecido aumenta en frecuencia
- Este tipo de selección produce una disminución de la diversidad genética

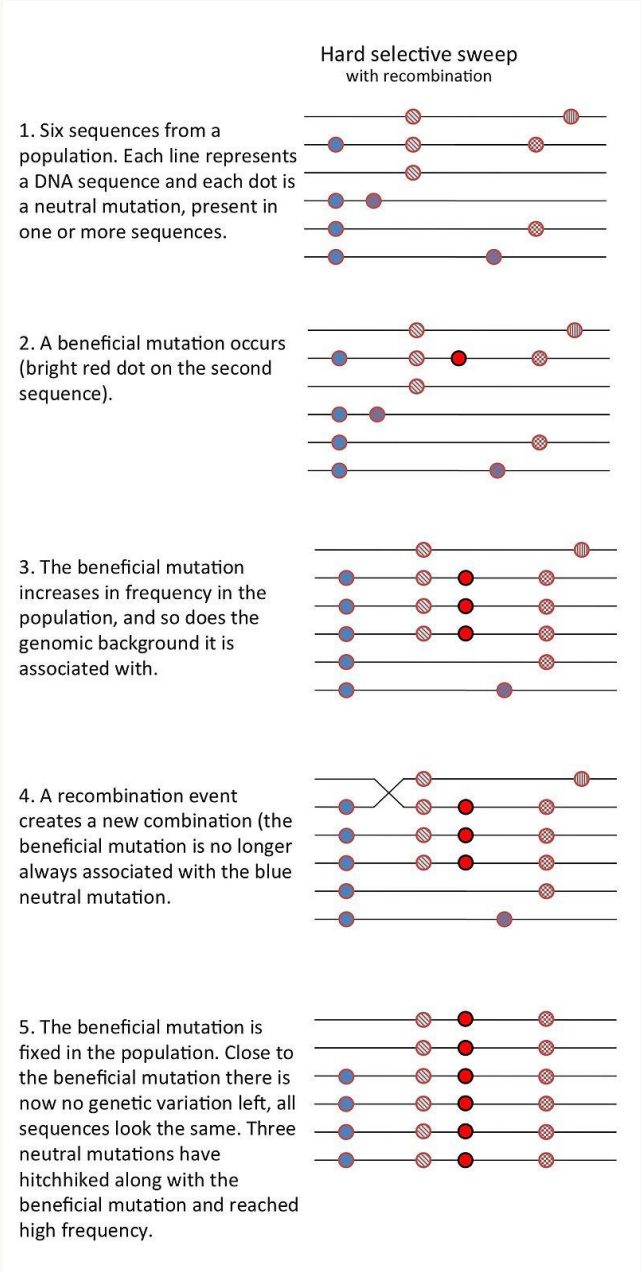

"Efecto autoestopista" (genetic hitchhicking): Aumento en la frecuencia de un alelo por efecto del desequilibrio de ligamiento que ocurre al estar espacialmente cerca de otro que es beneficioso y está experimentando un barrido selectivo.

Barrido selectivo (selective sweep): Reducción de la diversidad genética alrededor del alelo beneficioso debido a un desequilibrio de ligamiento.

Con el tiempo, se restaurará la diversidad por efecto de la recombinación y mutación

Selección positiva

Hard sweep: Barrido selectivo por aparición de una mutación de novo beneficiosa

Soft sweep: Barrido selectivo por ventaja adaptativa de un alelo existente o por varias mutaciones de novo beneficiosas

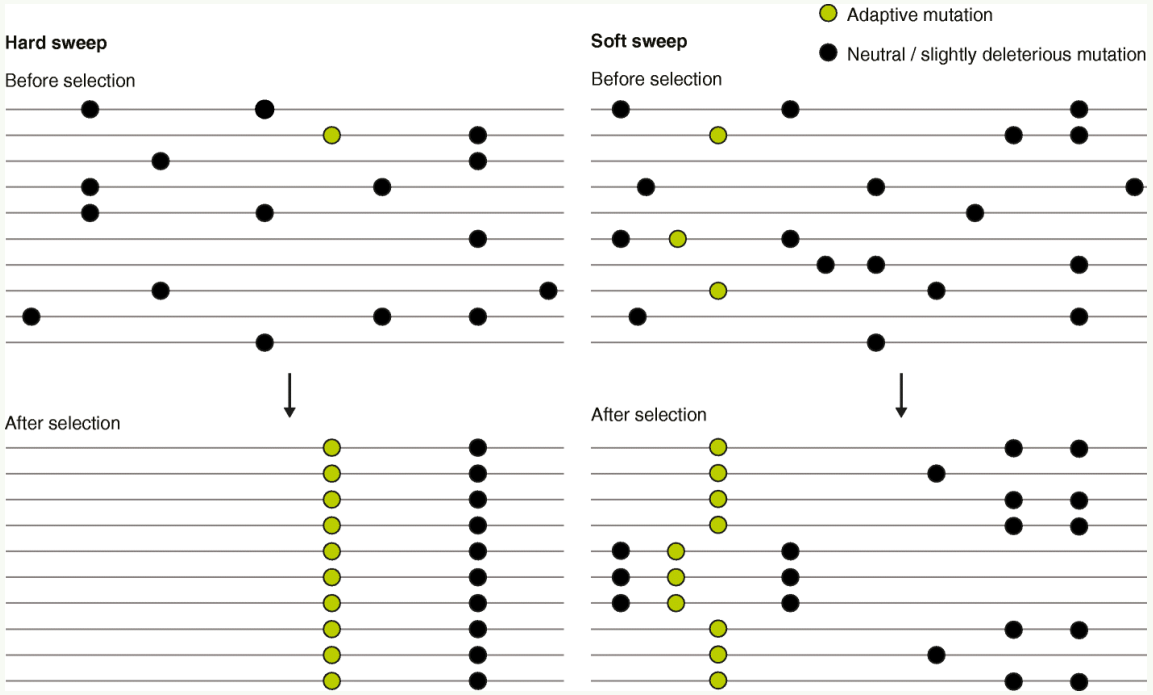

Efecto en la frecuencia alélica

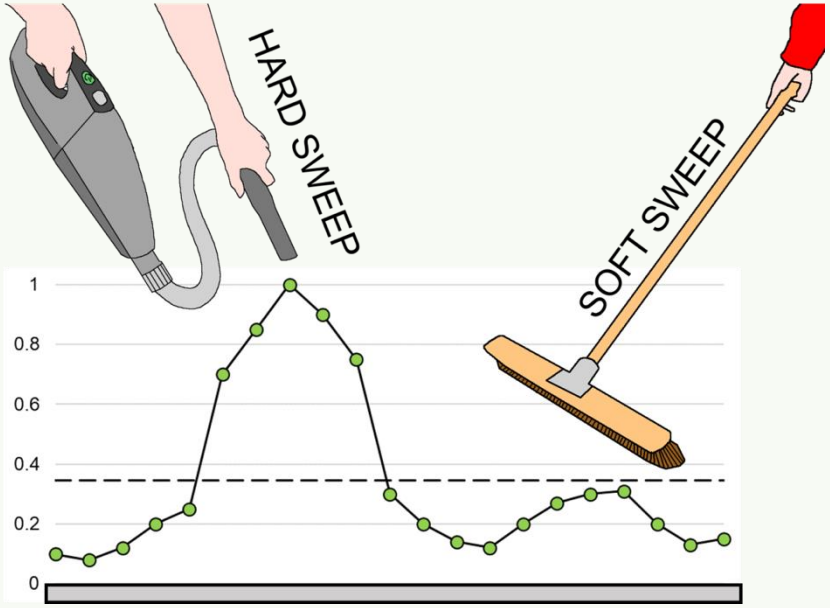

Efecto en la diversidad genética

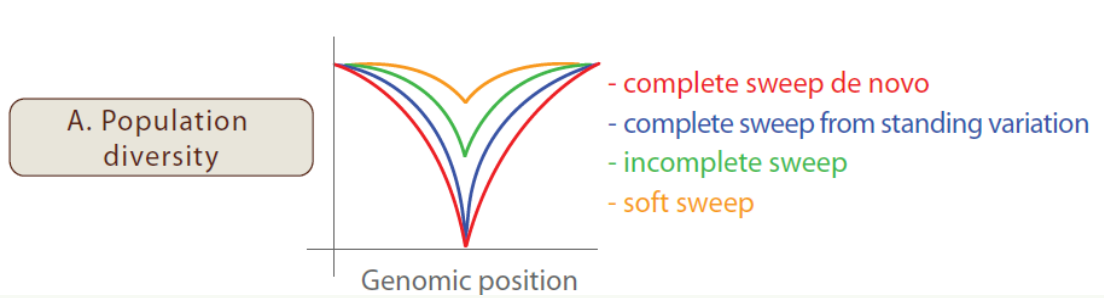

Selección positiva

I. DETECCIÓN

Métodos basados en la diferenciación poblacional

Métodos basados en el espectro de frecuencias

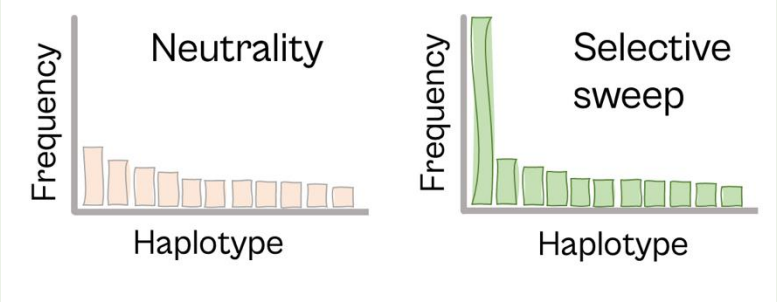

Métodos basados en el desequilibrio de ligamiento

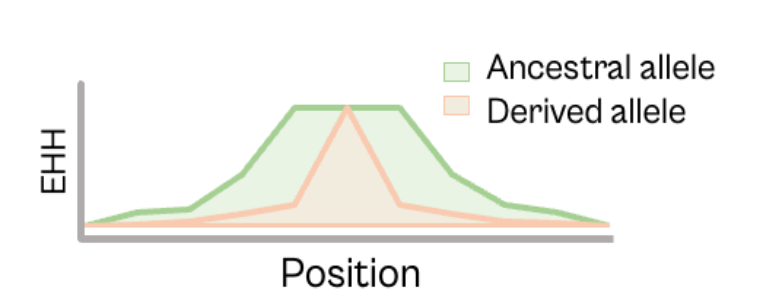

Métodos compuestos

Selección positiva

I. DETECCIÓN

Métodos basados en la diferenciación poblacional

Diferencias en las frecuencias alélicas en el locus que sustenta el rasgo adaptativo entre poblaciones

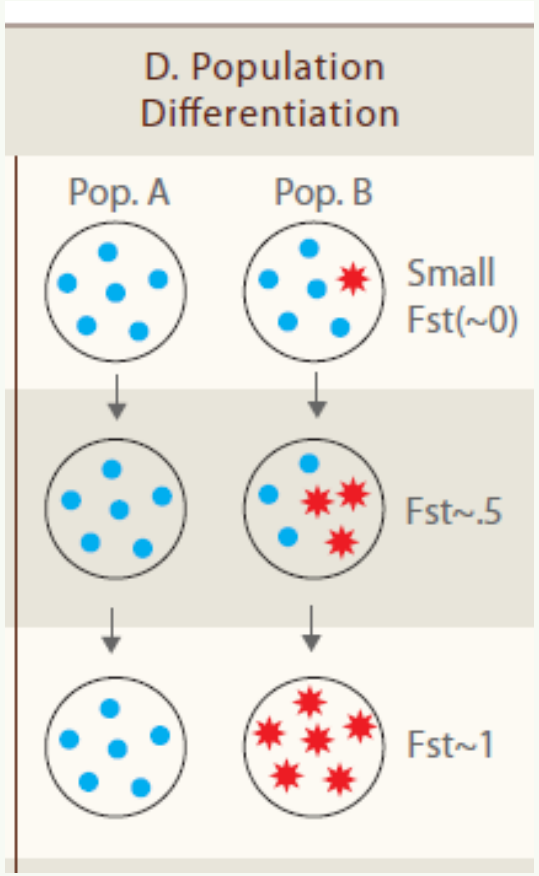

F_{ST}

- Debido al barrido selectivo, varios sitios en las proximidades del objetivo real de la selección podrían mostrar un alto F_{ST}
- El outlier de F_{ST} podría ser el objetivo real de la selección, o un sitio neutral vinculado a él.

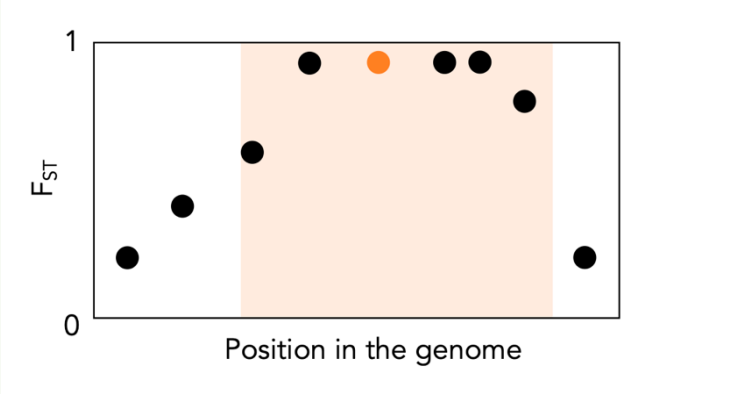

Selección positiva

I. DETECCIÓN

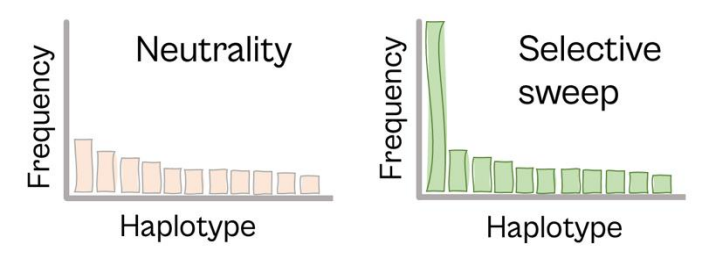

Métodos basados en el espectro de frecuencias

En un barrido selectivo, una variante genética alcanza una alta prevalencia junto con variantes ligadas cercanas (alelos derivados de alta frecuencia). A partir de este fondo homogéneo, surgen nuevos alelos, pero inicialmente son de baja frecuencia (excedente de alelos raros).

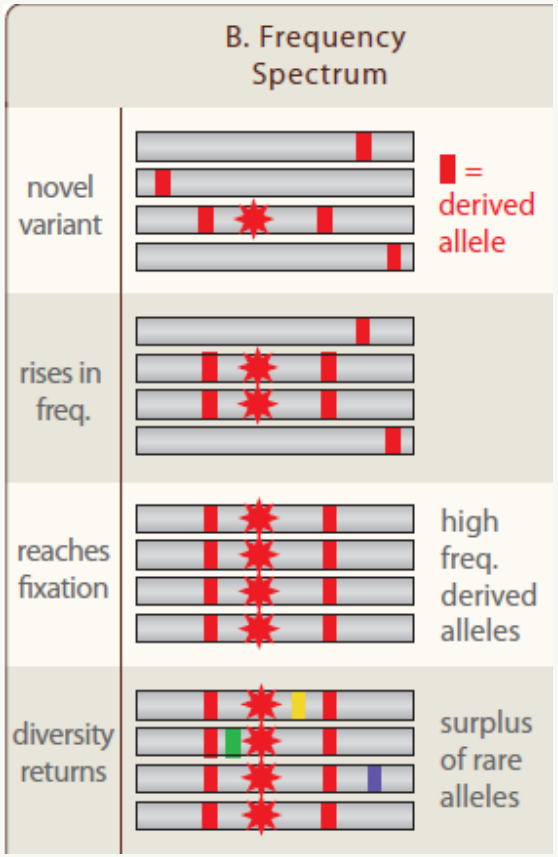

Tajima's D ($\pi - \theta$)

- Los alelos de baja frecuencia contribuyen menos al número de diferencias por pares en un conjunto de muestras que los alelos de frecuencia moderada
- Valores negativos de D sugieren un exceso de alelos raros, lo que puede ser indicativo de selección positiva o expansión de la población

Fay and Wu's H

- Se calcula como la diferencia normalizada en la diversidad genética entre las regiones de alta y baja frecuencia alélica.

  -H → exceso de SNPs derivados de alta frecuencia (mayor diversidad genética en las regiones de alta frecuencia alélica)

Selección positiva

I. DETECCIÓN

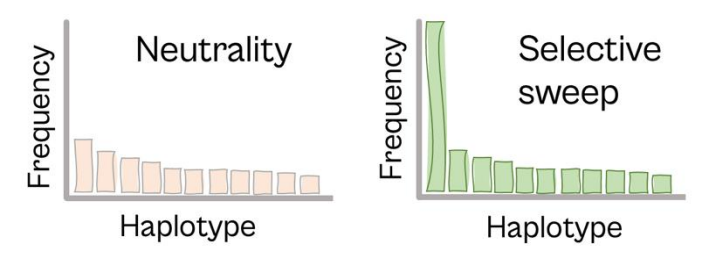

Métodos basados en el espectro de frecuencias

En un barrido selectivo, una variante genética alcanza una alta prevalencia junto con variantes ligadas cercanas (alelos derivados de alta frecuencia). A partir de este fondo homogéneo, surgen nuevos alelos, pero inicialmente son de baja frecuencia (excedente de alelos raros).

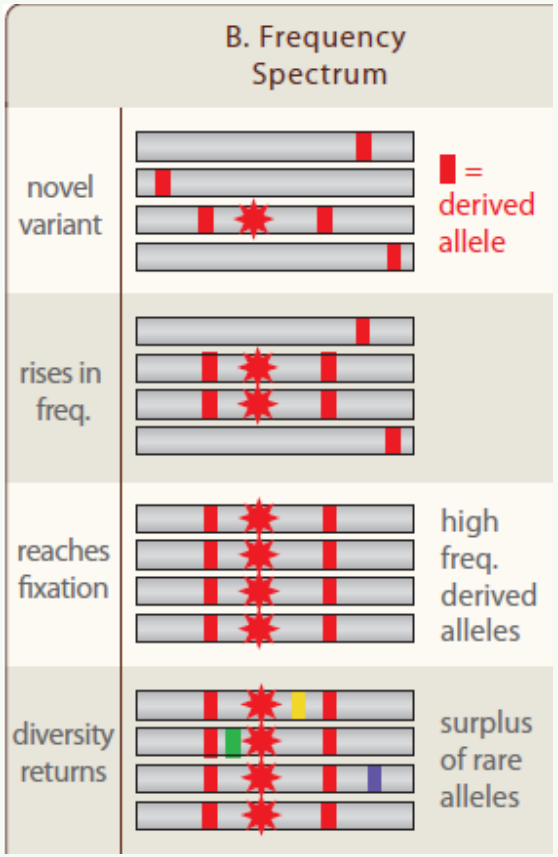

Tajima's D ($\pi - \theta$)

- Los alelos de baja frecuencia contribuyen menos al número de diferencias por pares en un conjunto de muestras que los alelos de frecuencia moderada
- Valores negativos de D sugieren un exceso de alelos raros, lo que puede ser indicativo de selección positiva o expansión de la población

Fay and Wu's H

- Se calcula como la diferencia normalizada en la diversidad genética entre las regiones de alta y baja frecuencia alélica.

  -H → exceso de SNPs derivados de alta frecuencia (mayor diversidad genética en las regiones de alta frecuencia alélica)

Selección positiva

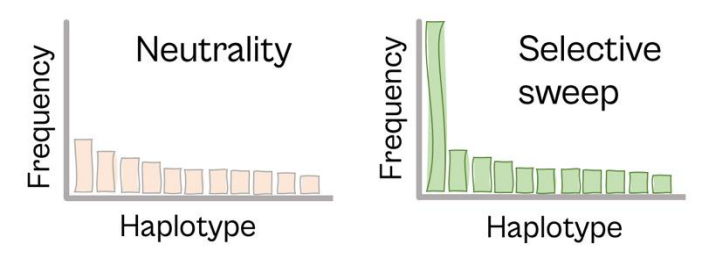

Métodos basados en el espectro de frecuencias

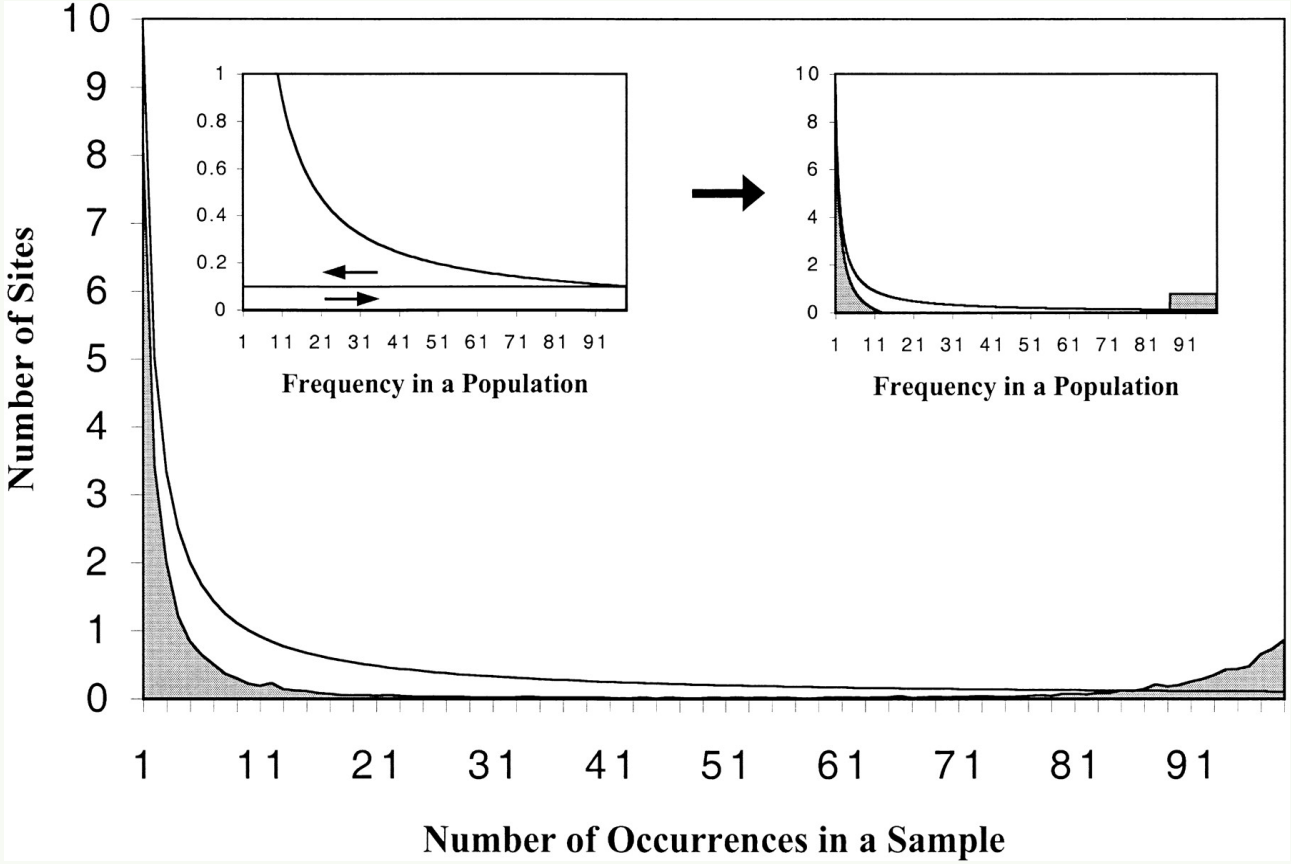

Tajima's D < 0

Exceso alelos raros

Fay and Wu's H < 0

Exceso de alelos derivados a alta frecuencia

Necesita outgroup (ancestral/derivado)

Selección positiva

I. DETECCIÓN

Métodos basados en el desequilibrio de ligamiento

- Buscan regiones con alto desequilibrio de ligamiento, es decir, haplotipos largos→ EHH
- Útil para identificar un barrido selectivo parcial o incompleto en lugar de fijados.

Un barrido selectivo hará que EHH se eleve a través del haplotipo que contiene el alelo seleccionado. La meseta de EHH alta comenzará a romperse cuando las nuevas mutaciones y la recombinación restauren gradualmente la diversidad de la población

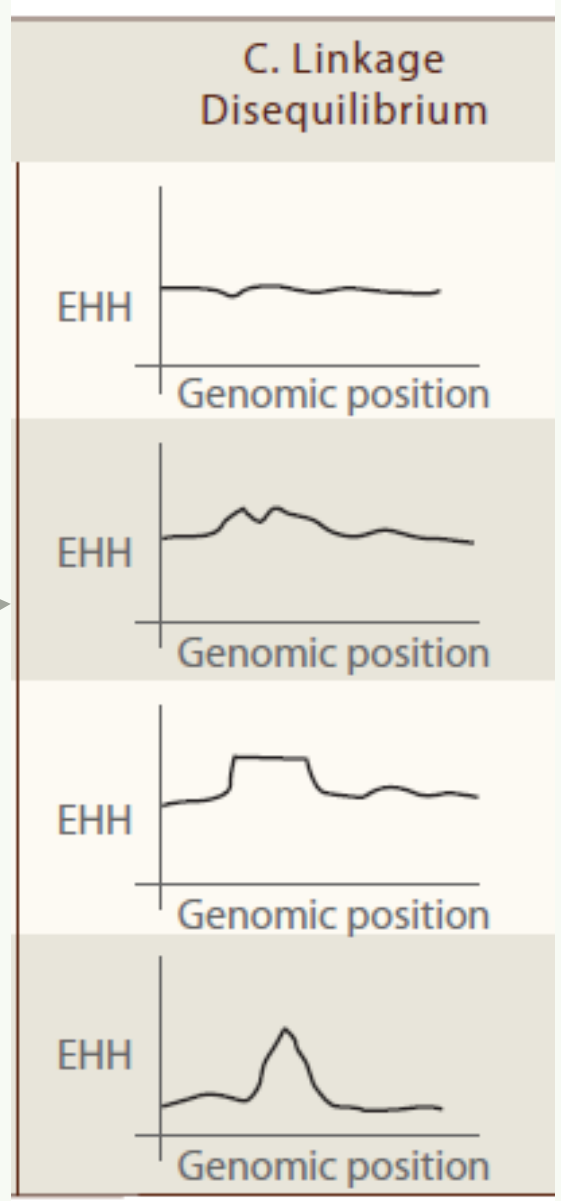

Selección positiva

I. DETECCIÓN

Métodos basados en el desequilibrio de ligamiento

- Buscan regiones con alto desequilibrio de ligamiento, es decir, haplotipos largos→ EHH
- Útil para identificar un barrido selectivo parcial o incompleto en lugar de fijados.

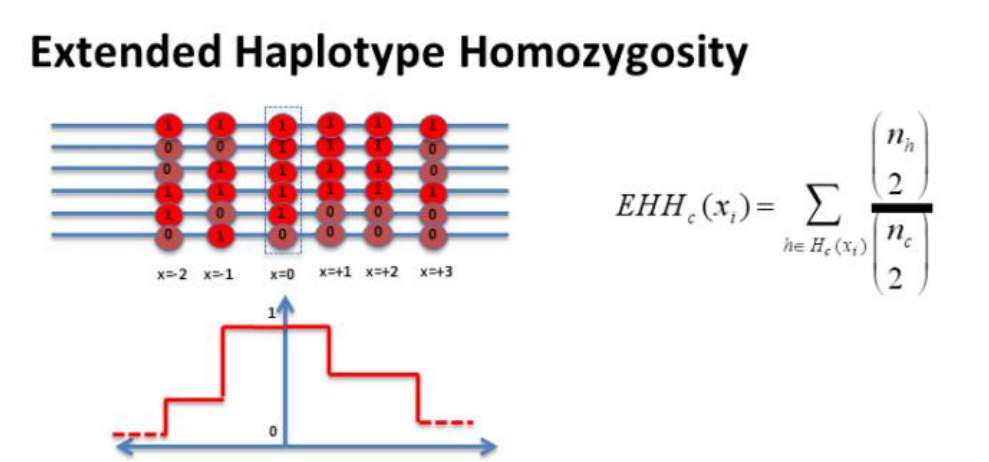

$$EHH_c(x_i) = \sum_{h \in H_c(x_i)} \frac{\binom{n_h}{2}}{\binom{n_c}{2}}$$

A medida que nos alejamos de la región central, EHH disminuye por acción de la recombinación

EHH se define desde una región central hasta una distancia específica en ambas direcciones y calcula la probabilidad de que dos cromosomas elegidos al azar dentro de la población portadora de la región central sean idénticos por descendencia para toda la región.

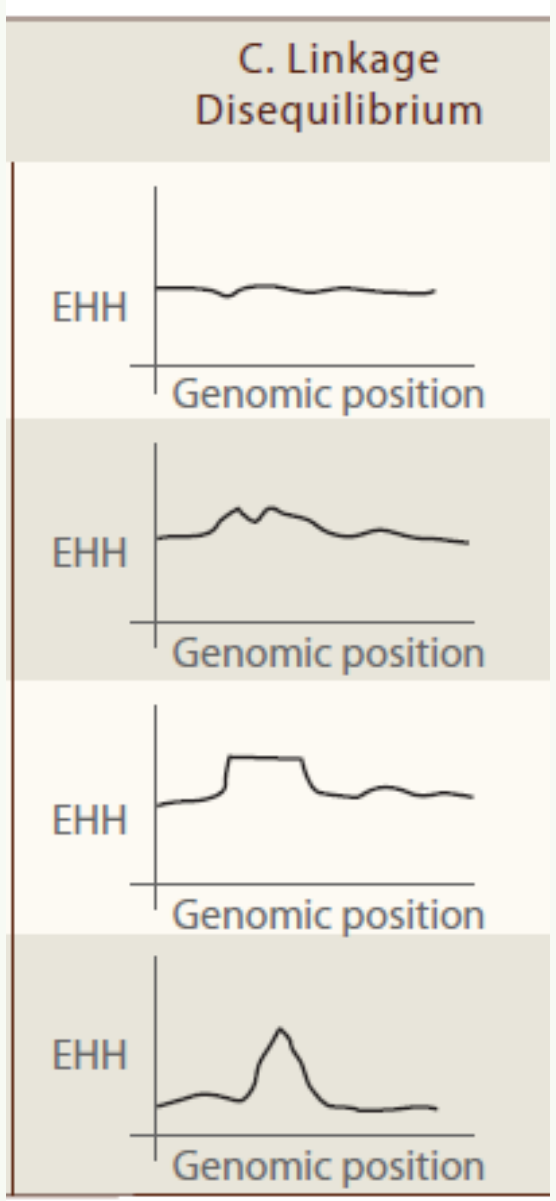

Selección positiva

I. DETECCIÓN

Métodos basados en el desequilibrio de ligamiento

- Buscan regiones con alto desequilibrio de ligamiento, es decir, haplotipos largos→ EHH
- Útil para identificar un barrido selectivo parcial o incompleto en lugar de fijados.

Integrated haplotype score (iHS) (barrido incompleto)

Toma el área bajo la curva definida por EHH captando que EHH extremos para una distancia corta y EHH moderados para una más larga son sugestivos de la acción de la selección

Cross-population extended haplotype homozygosity statistic (XP-EHH) (sweep cerca de fijación)

Compara las longitudes de los haplotipos entre poblaciones para controlar la variación local de las tasas de recombinación.

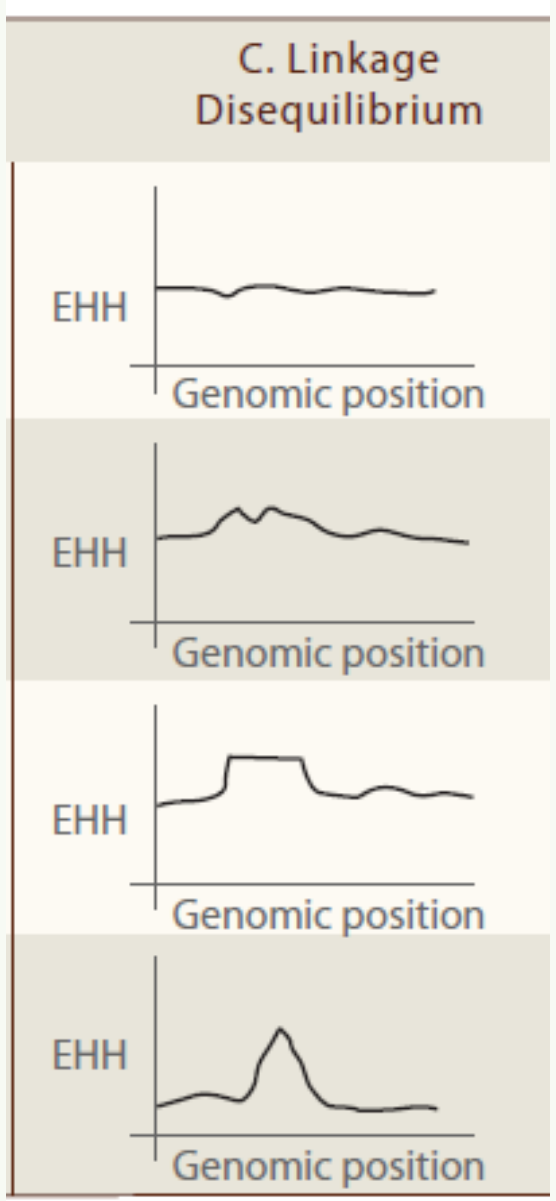

Selección positiva

I. DETECCIÓN

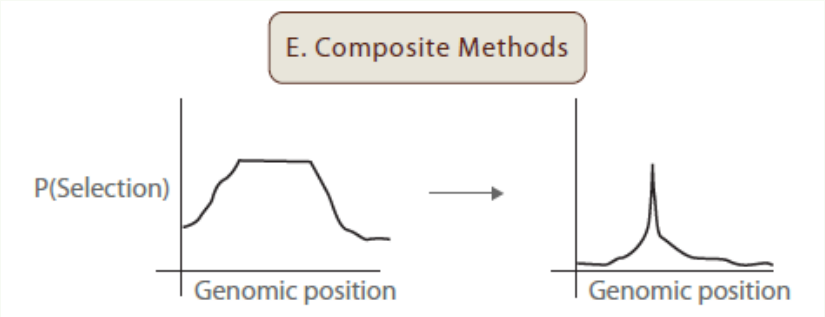

Métodos compuestos

Integran información de múltiples señales de selección y pueden proporcionar una resolución más fina al identificar variantes causales

- Mismo test en varios sitios (análisis basados en ventanas)

  Composite likelihood ratio (CLR) test

  Evaluates the probability of a selective event being responsible for a surplus of derived alleles across multiple sites. Uses LD-based data and goodness of fit test comparing composite likelihood calculated under a model where a sweep has occurred and under a model where no sweep.

  Cross-Population composite likelihood ratio (XP-CLR)

  Combines population diff signatures (Fst) with measures for high freq. derived alleles and excess of low freq. alleles

- Varios tests para un mismo sitio

  Unification of Tajima's D and Fay and Wu's H + Ewens-Watterson test

  EW test compares the pop H-W homozygosity to the predicted under a neutral model

  Multiple signal test (CMS)

  Integrates Fst, his and XP-EHH as well as ΔDAF tests for derived alleles high in freq relative to other pop. and ΔiHH that measures absolute length of haplotype

Selección positiva

Un método en ventanas del genoma

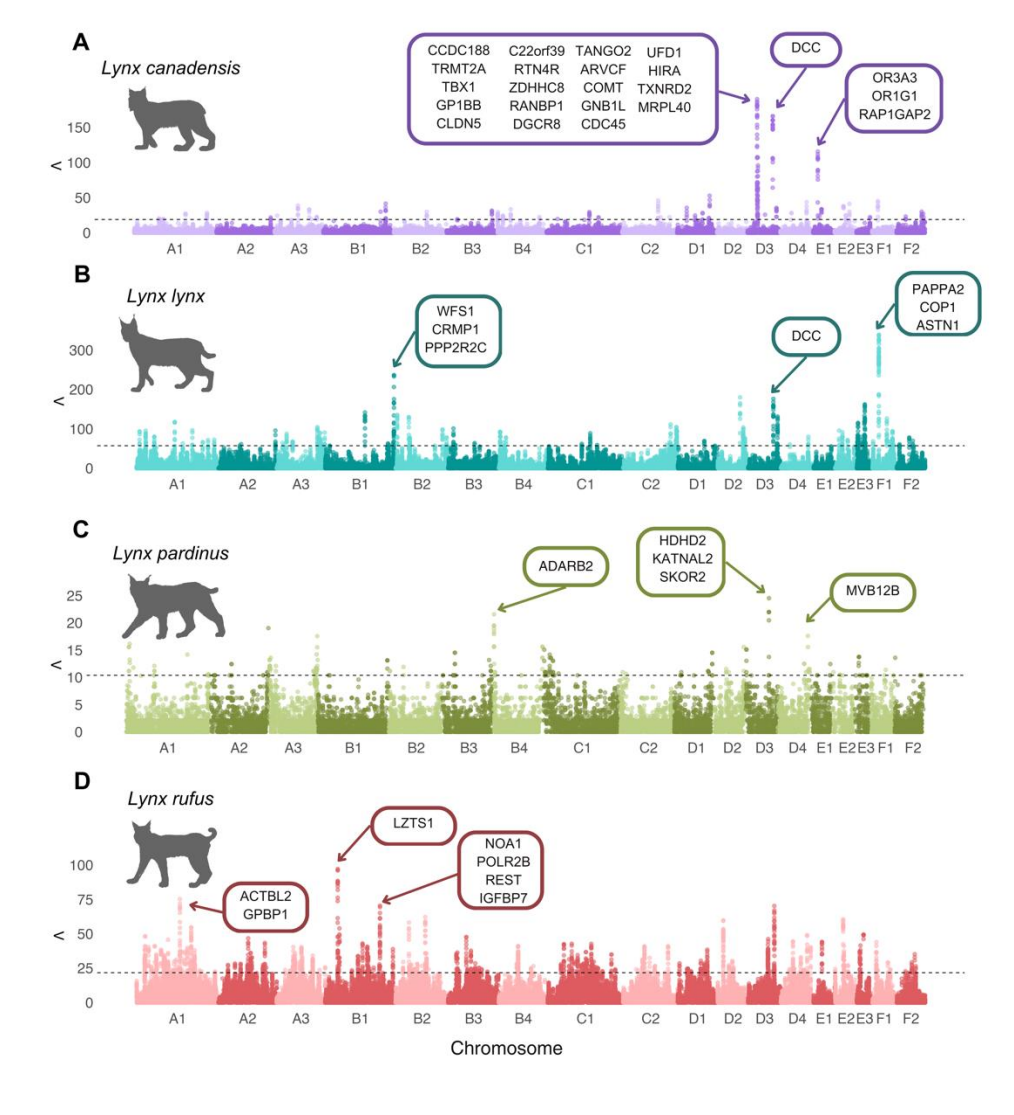

Varios métodos en una ventana del genoma

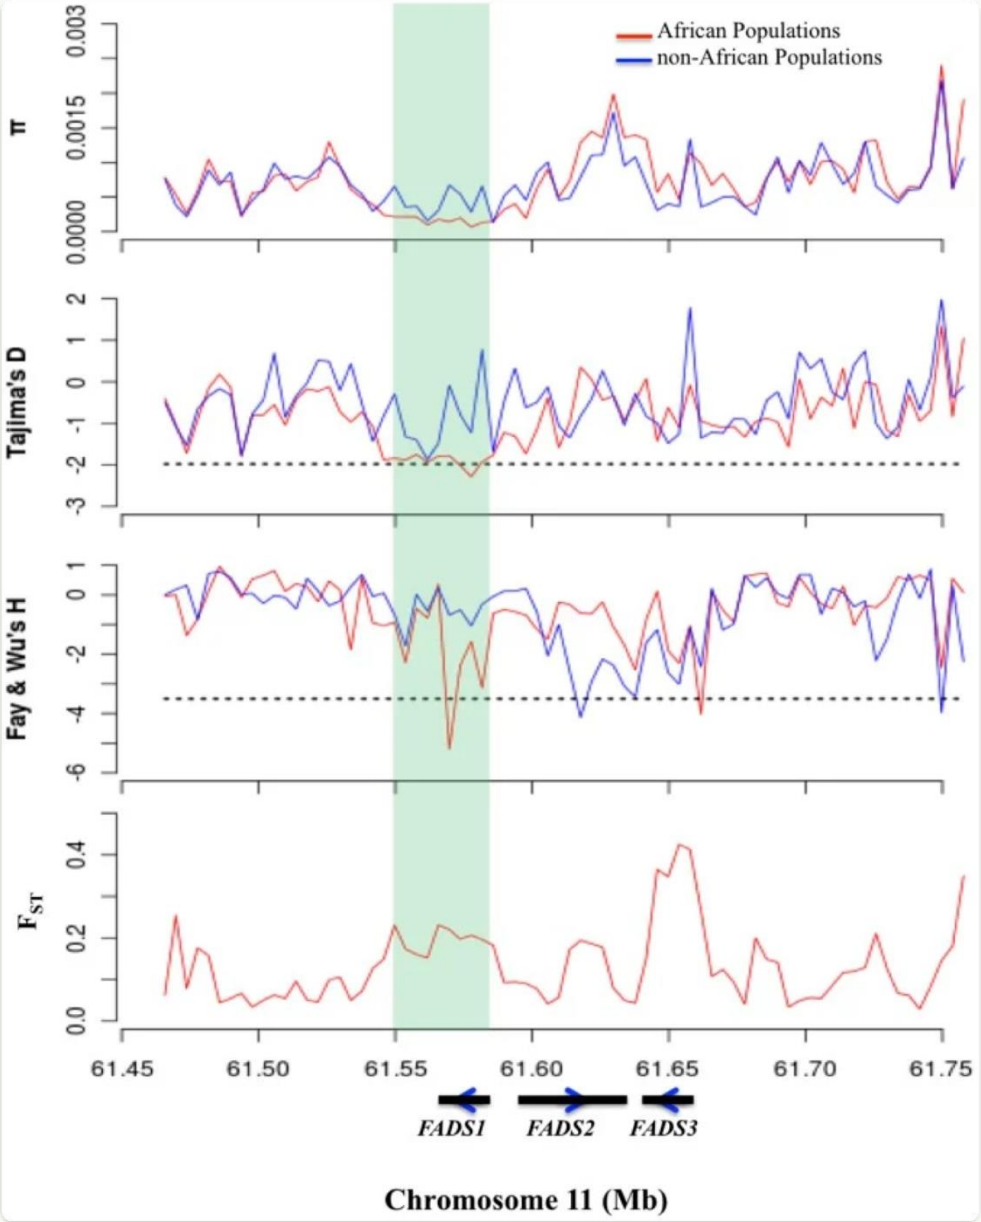

Selección positiva

II. GENOME ENVIRONMENT ASSOCIATION (GEA)

- Análisis de relación genotipo-ambiente
- Adaptación al ambiente, resiliencia al cambio climático

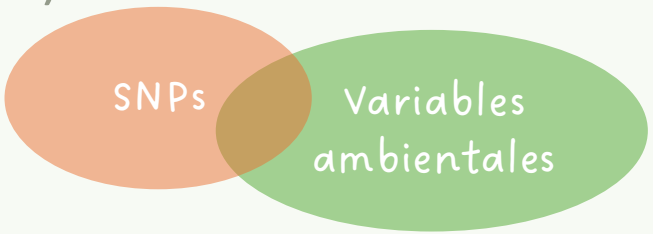

1. Obtención de datos ambientales y genéticos

   Datos de variables ambientales
   Genotipos

2. Asociación genética-ambiente

   BayPass: Asociación individual de cada predictor ambiental con los SNPs (fuerza y dirección)
   Redundancy Analyses (RDA): Resume la variación de los SNPs que se pueden explicar por un conjunto de variables ambientales

3. Obtención genes candidatos

   Outliers para la asociación

4. Enriquecimiento funcional

   Identificación de funciones/pathways con sobrerrepresentación funcional

ESTUDIOS

GEA

Received: 22 July 2022 | Revised: 18 May 2023 | Accepted: 6 June 2023
DOI: 10.1111/eva.13570

ORIGINAL ARTICLE

Evolutionary Applications WILEY

Genome-environment association analyses reveal geographically restricted adaptive divergence across the range of the widespread Eurasian carnivore *Lynx lynx* (Linnaeus, 1758)

Enrico Bazzicalupo[1] | Mirosław Ratkiewicz[2] | Ivan V. Seryodkin[3] | Innokentiy Okhlopkov[4] | Naranbaatar Galsandorj[5] | Yuriy A. Yarovenko[6] | Janis Ozolins[7] | Alexander P. Saveljev[8] | Dime Melovski[9] | Alexander Gavashelishvili[10] | Krzysztof Schmidt[11] | José A. Godoy[1]

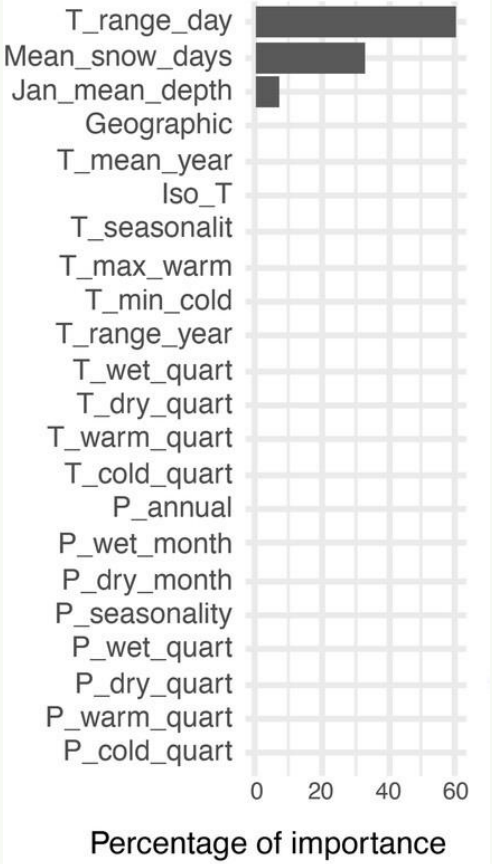

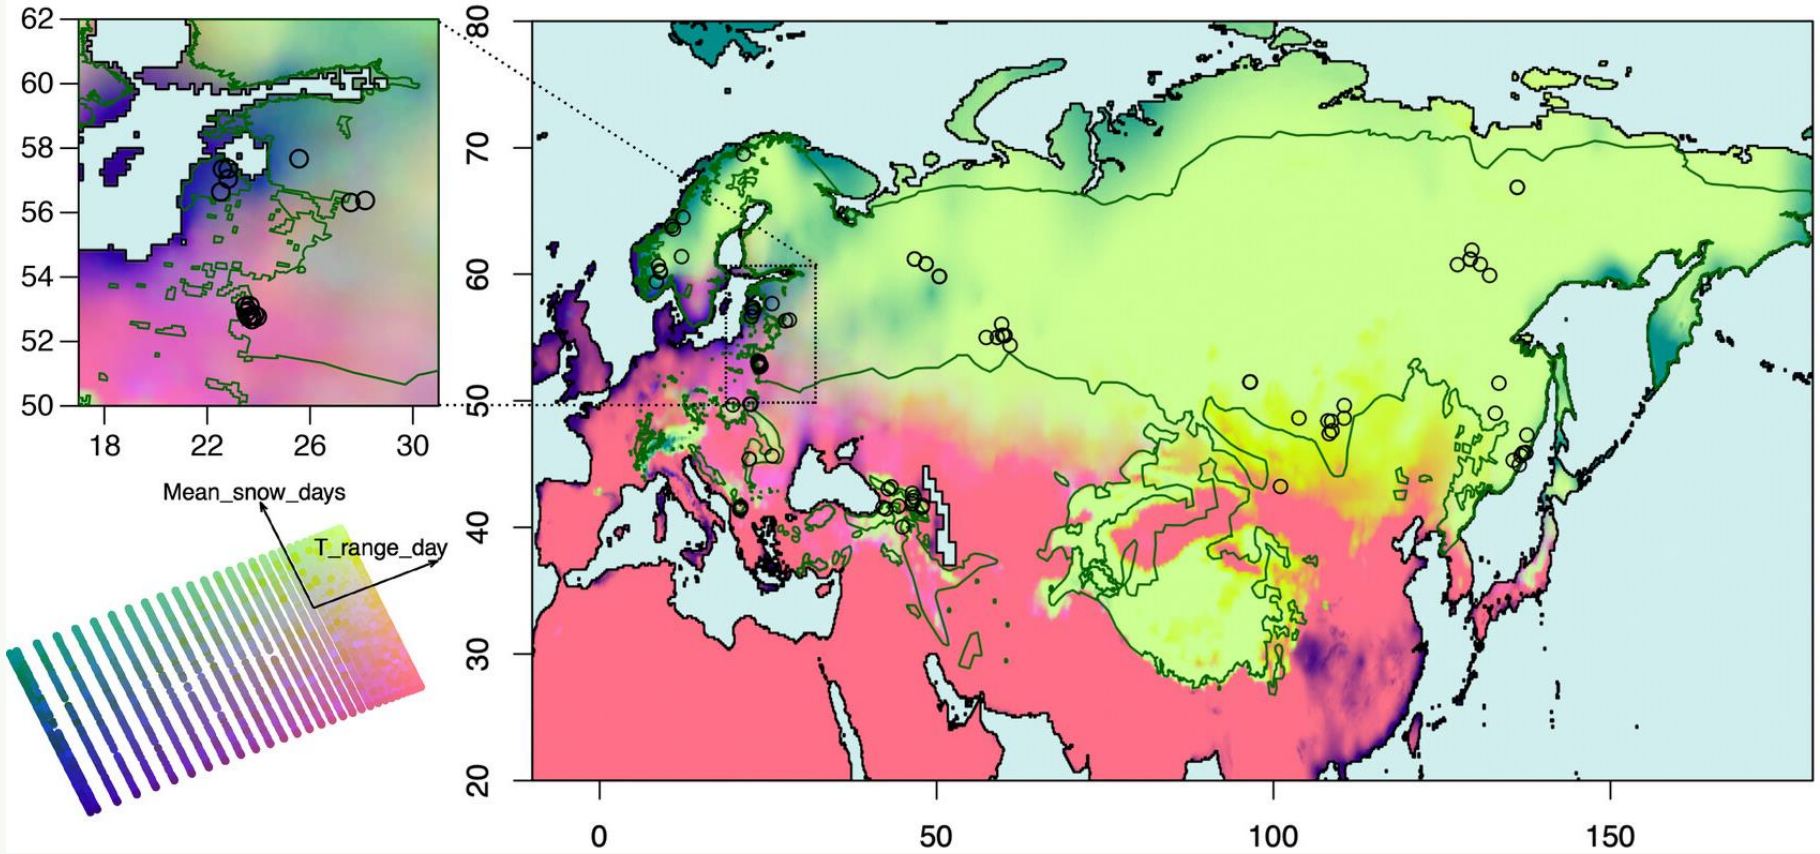

Selección positiva

III. GENOME WIDE ASSOCIATION STUDY (GWAS)

- Análisis de relación genotipo-fenotipo
- Caracterización genética de rasgos fenotípicos, enfermedades, fitness

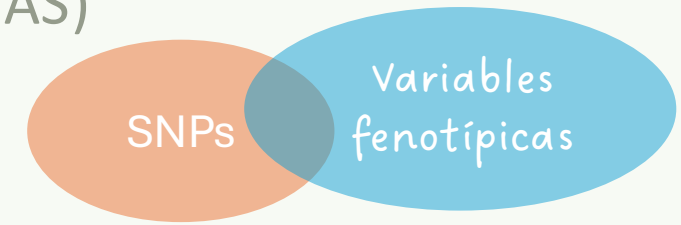

1. Obtención de datos fenotípicos y genéticos	Datos de variables morfológicas Genotipos
2. Asociación genética-fenotipo	Modelos de regresión (cuánto explican los SNPs el fenotipo observado)
3. Obtención genes candidatos	Outliers para la asociación (qué SNPs explican más)
4. Enriquecimiento funcional	Identificación de funciones/pathways con sobrerrepresentación funcional

ESTUDIOS

GWAS

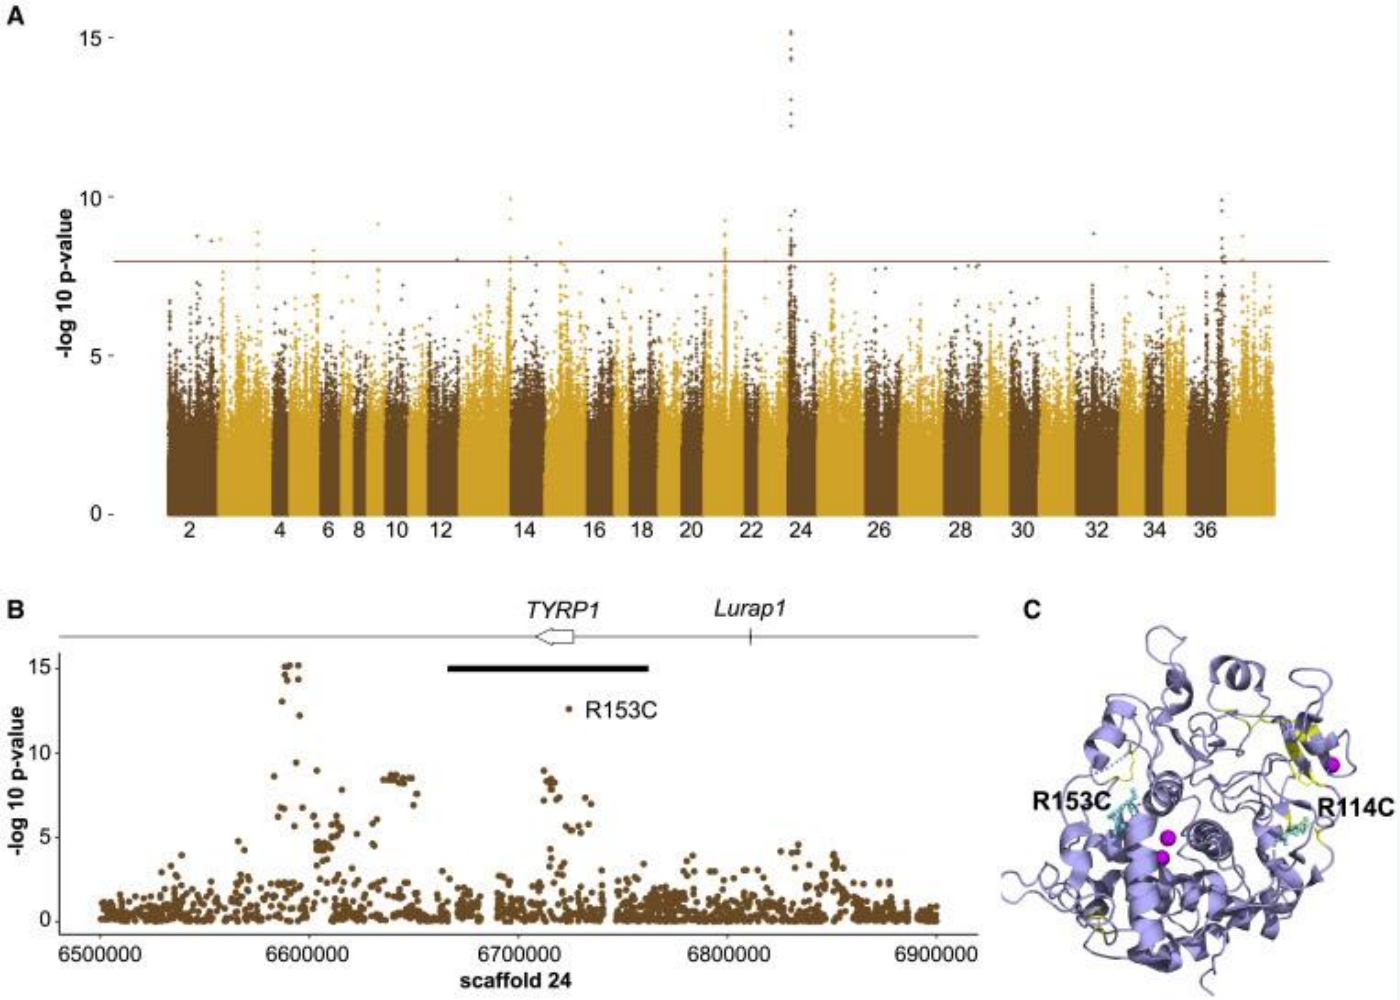

Current Biology

Volume 33, Issue 1, 9 January 2023, Pages 86-97.e10

Article

Genetic architecture and evolution of color variation in American black bears

Emily E. Puckett [1 30 31], Isis S. Davis [1 26], Dawn C. Harper [2], Kazumasa Wakamatsu [3], Gopal Battu [4], Jerrold L. Belant [5], Dean E. Beyer Jr. [5], Colin Carpenter [6], Anthony P. Crupi [7], Maria Davidson [8 27], Christopher S. DePerno [9], Nicholas Forman [10], Nicholas L. Fowler [7], David L. Garshelis [11 12], Nicholas Gould [9], Kerry Gunther [13], Mark Haroldson [14], Shosuke Ito [3], David Kocka [15], Carl Lackey [16]...Gregory S. Barsh [4 20]

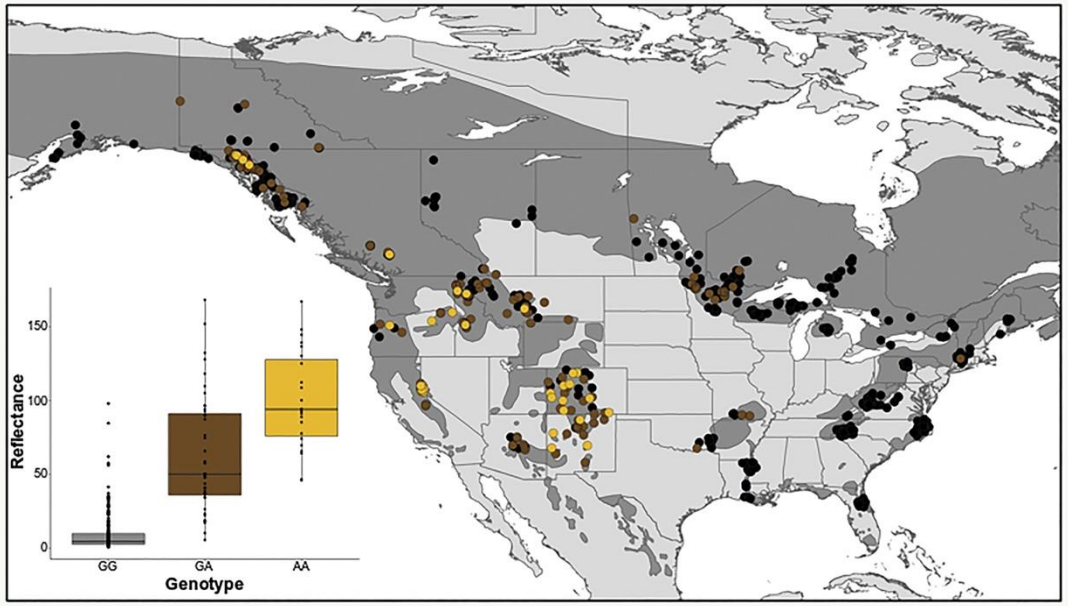

Selección positiva

IV. ENRIQUECIMIENTO FUNCIONAL

Cuando no tenemos un conocimiento a priori de las funciones que pueden estar bajo selección en nuestras poblaciones y hemos llevado a cabo técnicas de identificación de regiones de selección en todo el genoma, generalmente buscaremos asociación entre los genes ubicados en dichas regiones y funciones biológicas específicas

Gene set enrichment analyses (GSEA): Compara la lista de genes candidatos con una base de datos de anotaciones funcionales (como los GO terms) buscando determinar si algunas funciones están sobrerrepresentadas entre los genes encontrados en comparación con lo que se esperaría por azar, es decir, en comparación con la representación de cada función en todo el genoma de la especie en cuestión.

Gene ontology: Sistema de clasificación utilizado en biología para describir las funciones biológicas de los genes y proteínas. Estos términos están organizados en una estructura jerárquica y se utilizan para estandarizar la descripción de las funciones biológicas, procesos y componentes celulares en diversas especies.

Se clasifican en (GO terms):

- Procesos biológicos (BP)
- Funciones moleculares (MF)
- Componentes celulares (CC)

Selección positiva

IV. ENRIQUECIMIENTO FUNCIONAL

GO ENRICHMENT ANALYSES

SELECTION SCAN

Detección de regiones del genoma bajo selección

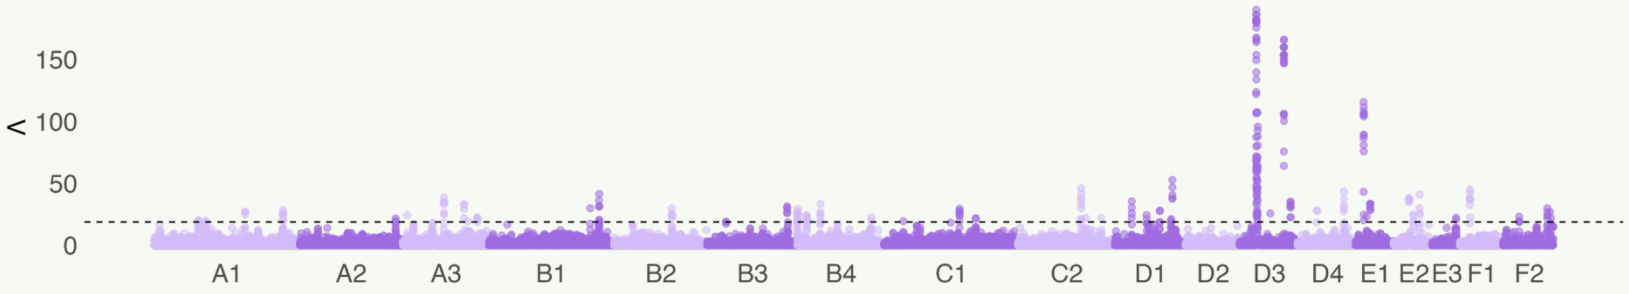

Selección positiva

IV. ENRIQUECIMIENTO FUNCIONAL

GO ENRICHMENT ANALYSES

SELECTION SCAN

Detección de regiones del genoma bajo selección

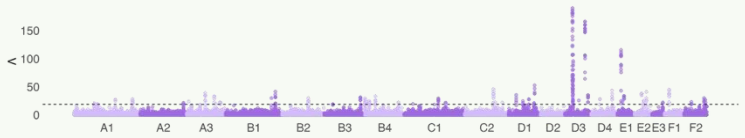

LISTA DE GENES CANDIDATOS

Identificación de los genes ubicados en dichas regiones

chr	start	end	snps_density	lassi_max	ihs_max	gene_start	gene_end	ensembl_id	gene_name
A1	8140283	8401210	350	16.7997	5.499695993	8216262	8233066	ENSFCAG00000008235	POMP
A1	8140283	8401210	350	16.7997	5.499695993	8241348	8261501	ENSFCAG00000008236	SLC46A3
A1	85660448	86044561	350	19.621	8.804582128	85674970	85675914	ENSFCAG00000010099	OR2W3
A1	85660448	86044561	350	19.621	8.804582128	85647692	85664396	ENSFCAG00000012687	TRIM58
A1	154926179	155391322	200	7.31193	8.517426992	155039309	155056392	ENSFCAG00000022808	CETN3
A1	154926179	155391322	200	7.31193	8.517426992	155097584	155115080	ENSFCAG00000029005	MBLAC2
A1	154926179	155391322	200	7.31193	8.517426992	155160641	155173842	ENSFCAG00000029406	LYSMD3
A1	154926179	155391322	200	7.31193	8.517426992	155202961	155768287	ENSFCAG00000012405	ADGRV1
A1	172562587	173024606	300	12.2697	4.389894793	172838765	172870048	ENSFCAG00000046336	SLC25A46
A1	172562587	173024606	300	12.2697	4.389894793	172624706	172815409	ENSFCAG00000010837	TMEM232
A2	79349532	79803102	250	10.2348	5.931211415	79308199	79416190	ENSFCAG00000030777	PRKAR2B
A2	79349532	79803102	250	10.2348	5.931211415	79536254	79569744	ENSFCAG00000004554	PIK3CG
A2	82307295	82632601	200	7.82089	8.638791507	82323935	82861458	ENSFCAG00000000639	RELN

Selección positiva

IV. ENRIQUECIMIENTO FUNCIONAL

GO ENRICHMENT ANALYSES

SELECTION SCAN

Detección de regiones del genoma bajo selección

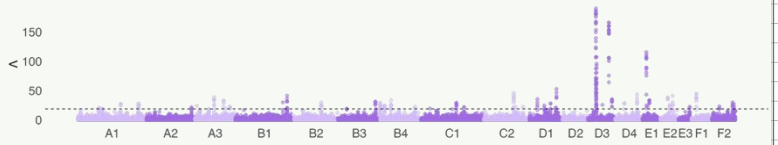

LISTA DE GENES CANDIDATOS

Identificación de los genes ubicados en dichas regiones

chr	start	end	snps_density	lassi_max	ihs_max	gene_start	gene_end	ensembl_id	gene_name
A1	8140283	8401210	350	16.7997	5.499695993	8216262	8233066	ENSFCAG00000008235	POMP
A1	8140283	8401210	350	16.7997	5.499695993	8241348	8261501	ENSFCAG00000008236	SLC46A3
A1	85660448	86044561	350	19.621	8.804582128	85674970	85675914	ENSFCAG00000010099	OR2W3
A1	85660448	86044561	350	19.621	8.804582128	85647692	85664396	ENSFCAG00000012687	TRIM58
A1	154926179	155391322	200	7.31193	8.517426992	155039309	155056392	ENSFCAG00000022808	CETN3
A1	154926179	155391322	200	7.31193	8.517426992	155097584	155115080	ENSFCAG00000029005	MBLAC2
A1	154926179	155391322	200	7.31193	8.517426992	155160641	155173842	ENSFCAG00000029406	LYSMD3
A1	154926179	155391322	200	7.31193	8.517426992	155202961	155768287	ENSFCAG00000012405	ADGRV1
A1	172562587	173024606	300	12.2697	4.389894793	172838765	172870048	ENSFCAG00000046336	SLC25A46
A1	172562587	173024606	300	12.2697	4.389894793	172624706	172815409	ENSFCAG00000010837	TMEM232
A2	79349532	79803102	250	10.2348	5.931211415	79308199	79416190	ENSFCAG00000030777	PRKAR2B
A2	79349532	79803102	250	10.2348	5.931211415	79536254	79569744	ENSFCAG00000004554	PIK3CG
A2	82307295	82632601	200	7.82089	8.638791507	82323935	82861458	ENSFCAG00000000639	RELN

TEST DE SOBRERREPRESENTACIÓN

Compara mi lista de genes candidatos con la lista total (anotación del genoma de referencia) buscando sobrerrepresentación funcional

GO TERMS

- PROCESOS BIOLÓGICOS
- FUNCIONES MOLECULARES
- COMPONENTES CELULARES

Selección positiva

IV. ENRIQUECIMIENTO FUNCIONAL

GO ENRICHMENT ANALYSES

GO.ID	Term	Annotated	Significant	Expected	Fisher	p.adj	ontology
GO:0007186	G protein-coupled receptor signaling pat...	1342	44	15.6	4E-11	0	BP
GO:0050911	detection of chemical stimulus involved ...	451	24	5.24	5.7E-10	0	BP
GO:1904659	glucose transmembrane transport	82	4	0.95	0.00077	0.0385	BP
GO:0048015	phosphatidylinositol-mediated signaling	16	3	0.19	0.00078	0.0385	BP
GO:0006833	water transport	17	3	0.2	0.00093	0.0385	BP
GO:0043124	negative regulation of canonical NF-kapp...	42	4	0.49	0.00140	0.0483	BP
GO:0004984	olfactory receptor activity	687	38	8.32	2.7E-15	0	MF
GO:0004930	G protein-coupled receptor activity	1069	42	12.94	1.4E-11	0	MF
GO:0005886	plasma membrane	3853	82	45.93	3.1E-09	0	CC
GO:0043198	dendritic shaft	12	3	0.14	0.00034	0.0367	CC

TEST DE SOBRERREPRESENTACIÓN

Compara mi lista de genes candidatos con la lista total (anotación del genoma de referencia) buscando sobrerrepresentación funcional

GO TERMS

- PROCESOS BIOLÓGICOS
- FUNCIONES MOLECULARES
- COMPONENTES CELULARES

Selección positiva

IV. ENRIQUECIMIENTO FUNCIONAL

GO ENRICHMENT ANALYSES

SELECTION SCAN

Detección de regiones del genoma bajo selección

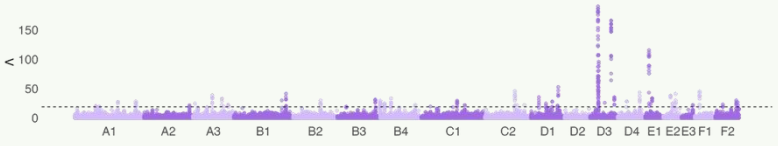

LISTA DE GENES CANDIDATOS

Identificación de los genes ubicados en dichas regiones

chr	start	end	snps_density	lassi_max	ihs_max	gene_start	gene_end	ensembl_id	gene_name
A1	8140283	8401210	350	16.7997	5.499695993	8216262	8233066	ENSFCAG00000008235	POMP
A1	8140283	8401210	350	16.7997	5.499695993	8241348	8261501	ENSFCAG00000008236	SLC46A3
A1	85660448	86044561	350	19.621	8.804582128	85674970	85675914	ENSFCAG00000010099	OR2W3
A1	85660448	86044561	350	19.621	8.804582128	85647692	85664396	ENSFCAG00000012687	TRIM58
A1	154926179	155391322	200	7.31193	8.517426992	155039309	155056392	ENSFCAG00000022808	CETN3
A1	154926179	155391322	200	7.31193	8.517426992	155097584	155115080	ENSFCAG00000029005	MBLAC2
A1	154926179	155391322	200	7.31193	8.517426992	155160641	155173842	ENSFCAG00000029406	LYSMD3
A1	154926179	155391322	200	7.31193	8.517426992	155202961	155768287	ENSFCAG00000012405	ADGRV1
A1	172562587	173024606	300	12.2697	4.389894793	172838765	172870048	ENSFCAG00000046336	SLC25A46
A1	172562587	173024606	300	12.2697	4.389894793	172624706	172815409	ENSFCAG00000010837	TMEM232
A2	79349532	79803102	250	10.2348	5.931211415	79308199	79416190	ENSFCAG00000030777	PRKAR2B
A2	79349532	79803102	250	10.2348	5.931211415	79536254	79569744	ENSFCAG00000004554	PIK3CG
A2	82307295	82632601	200	7.82089	8.638791507	82323935	82861458	ENSFCAG00000000639	RELN

TEST DE SOBRERREPRESENTACIÓN

Compara mi lista de genes candidatos con la lista total (anotación del genoma de referencia) buscando sobrerrepresentación funcional

GO.ID	Term	Annotated	Significant	Expected	Fisher	p.adj	ontology
GO:0007186	G protein-coupled receptor signaling pat...	1342	44	15.6	4E-11	0	BP
GO:0050911	detection of chemical stimulus involved ...	451	24	5.24	5.7E-10	0	BP
GO:1904659	glucose transmembrane transport	82	4	0.95	0.00077	0.0385	BP
GO:0048015	phosphatidylinositol-mediated signaling	16	3	0.19	0.00078	0.0385	BP
GO:0006833	water transport	17	3	0.2	0.00093	0.0385	BP
GO:0043124	negative regulation of canonical NF-kapp...	42	4	0.49	0.00140	0.0483	BP
GO:0004984	olfactory receptor activity	687	38	8.32	2.7E-15	0	MF
GO:0004930	G protein-coupled receptor activity	1069	42	12.94	1.4E-11	0	MF
GO:0005886	plasma membrane	3853	82	45.93	3.1E-09	0	CC
GO:0043198	dendritic shaft	12	3	0.14	0.00034	0.0367	CC

https://github.com/lorenalorenzo/Functional_enrichment

Selección positiva
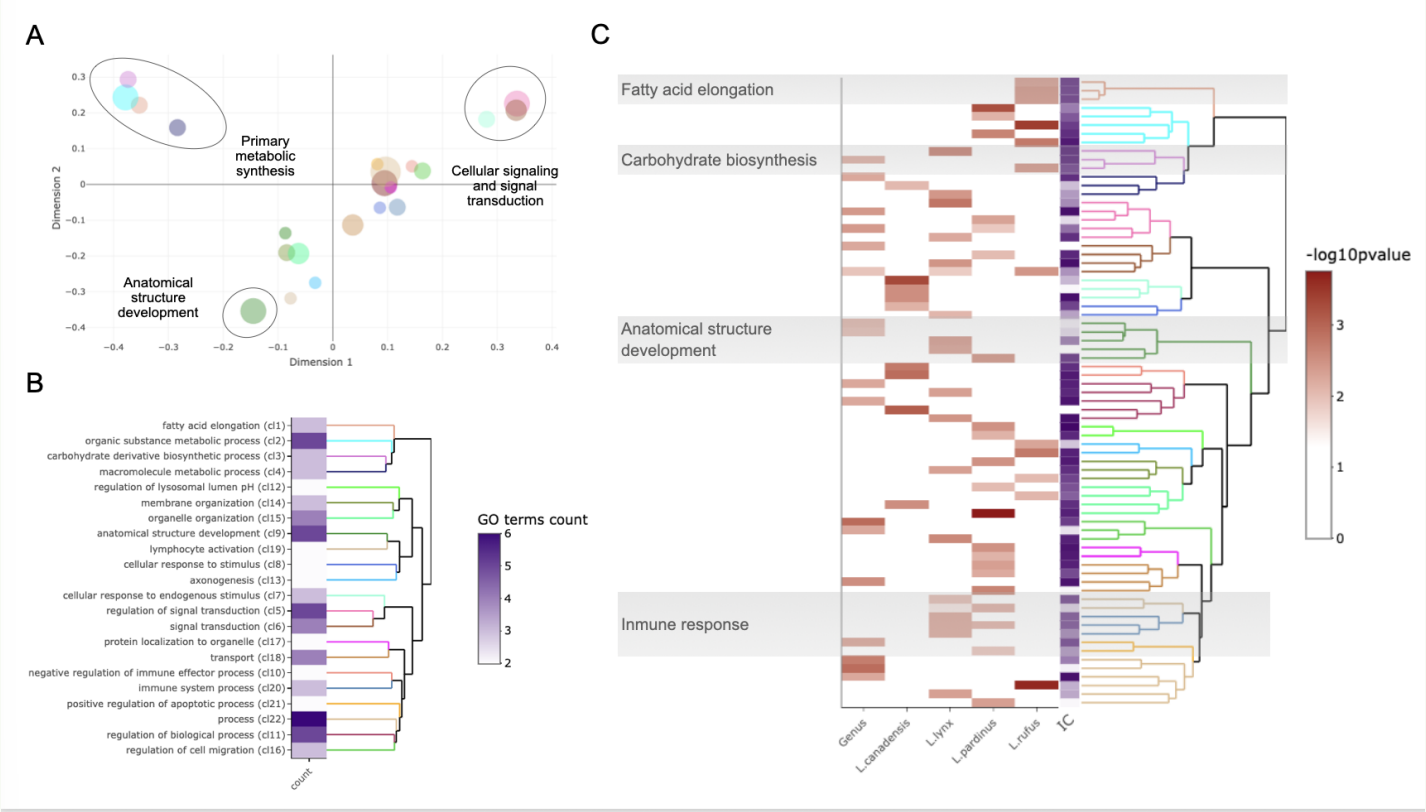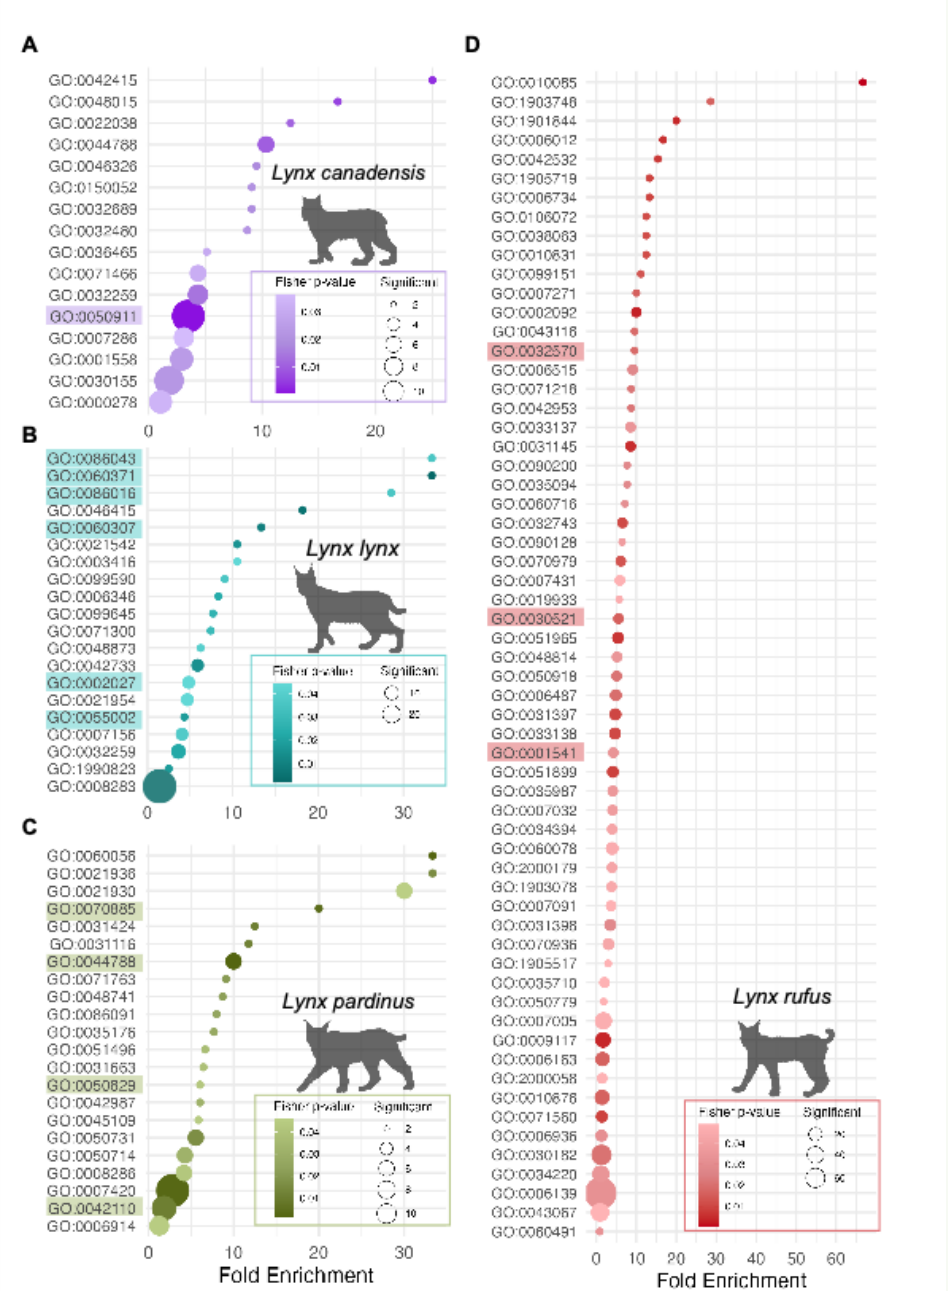
Visualización del ENRIQUECIMIENTO FUNCIONAL